

# Control computarizado - Mínimos cuadrados


Kjartan Halvorsen

July 17, 2020


# Identificación de sistemas

# Un proceso complejo


From Wikipedia "Cyclonic separation"



# Identificación de sistemas



## Ajustando un modelo




# Ajustando un modelo - regresión lineal

**Objetivo** Dado observaciones

$$\mathcal{D} = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$$

y modelo  $\mathcal{M} : y = ax + b + e$ ,  
obtiene los parametros  $(a, b)$  que  
da el modelo que mejor se ajuste a  
los datos.

El término de ruido, o error,  $e$ ,  
incluye errores de modelación y  
perturbaciones.



## Ajustando un modelo - regresión lineal

Dado observaciones  $\mathcal{D} = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$  y modelo

$$\mathcal{M}: y = ax + b + e.$$

La predicción es


$$\hat{y}_k = ax_k + b = \underbrace{\begin{bmatrix} x & 1 \end{bmatrix}}_{\varphi_k^T} \underbrace{\begin{bmatrix} a \\ b \end{bmatrix}}_{\theta}$$

y el error de predicción

$$\epsilon_k = y_k - \hat{y}_k = y_k - ax_k - b = y - \varphi_k^T \theta.$$

Buscamos parametros  $\theta^T = [a \quad b]$  que minimiza la función de pérdida

$$J(\theta) = \sum_{k=1}^N g(\epsilon_k).$$




## Ajustando un modelo - regresión lineal

Dado observaciones  $\mathcal{D} = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$  y modelo

$\mathcal{M}: y = ax + b + e$ .

La función de pérdida más común es **mínimos cuadrados**

$$\begin{aligned}\hat{\theta}_{LS} &= \arg \min J_{LS}(\theta) = \arg \min \sum_{k=1}^N \epsilon_k^2 \\ &= \arg \min \sum_{k=1}^N (y_k - \hat{y}_k)^2 = \arg \min \sum_{k=1}^N (y_k - \varphi_k \theta)^2 \\ &= \arg \min \sum_{k=1}^N (y_k - ax_k - b)^2\end{aligned}$$






## El problema con mínimos cuadrados

$$\text{minimiza } \sum_k g(\epsilon_k)$$

dónde  $g(u) = u^2$




# Más robusta: La función de pérdida de Huber

También conocido como **regresión robusta**

$$\text{minimiza } \sum_k g_{hub}(\epsilon_k)$$

$$\text{dónde } g_{hub}(u) = \begin{cases} u^2 & |u| \leq M \\ M(2|u| - M) & |u| > M \end{cases}$$



## Ejemplo - Modelo autorregresivo (AR)

# Modelo autorregresivo (AR)

Dado una secuencia discreta observada  $y(k)$ ,  $k = 1, 2, \dots, N$ , y el modelo autorregresivo

$$y(k+1) = -ay(k) + e(k+1),$$

dónde  $e(k)$  es una secuencia discreto de ruido blanco.

**Objetivo** Estimar el parametro  $a$ .

1. Forma el predictor de un paso adelante

$$\hat{y}_{k+1} = -ay_k = -y_k a = \varphi_{k+1} \theta,$$

y el error de predicción

$$\epsilon_k = y_k - \hat{y}_k = y_k - \varphi_k \theta$$

## Modelo autorregresivo (AR)

Dado una secuencia discreta observada  $y(k)$ ,  $k = 1, 2, \dots, N$ , y el modelo autorregresivo  $y(k+1) = -ay(k) + e(k+1)$ , donde  $e(k)$  es una secuencia discreto de ruido blanco.

**Objetivo** Estimar el parametro  $a$ .

2. Reune todas las observaciones  $y_k$  y predicciones  $\hat{y}_k$  en forma vectoral

$$\begin{aligned}\epsilon &= \begin{bmatrix} \epsilon_2 \\ \epsilon_2 \\ \vdots \\ \epsilon_N \end{bmatrix} = \begin{bmatrix} y_2 \\ y_3 \\ \vdots \\ y_N \end{bmatrix} - \begin{bmatrix} \hat{y}_2 \\ \hat{y}_3 \\ \vdots \\ \hat{y}_N \end{bmatrix} = \begin{bmatrix} y_2 \\ y_3 \\ \vdots \\ y_N \end{bmatrix} - \begin{bmatrix} -y_1 a \\ -y_2 a \\ \vdots \\ -y_{N-1}^T \theta \end{bmatrix} = \begin{bmatrix} y_2 \\ y_3 \\ \vdots \\ y_N \end{bmatrix} - \begin{bmatrix} \varphi_2^T \theta \\ \varphi_3^T \theta \\ \vdots \\ \varphi_N^T \theta \end{bmatrix} \\ &= y - \underbrace{\begin{bmatrix} \varphi_1^T \\ \varphi_2^T \\ \vdots \\ \varphi_N^T \end{bmatrix}}_{\Phi} \theta = y - \Phi \theta\end{aligned}$$

## Modelo autorregresivo (AR)

Dado una secuencia discreta observada  $y(k)$ ,  $k = 1, 2, \dots, N$ , y el modelo autorregresivo  $y(k+1) = -ay(k) + e(k+1)$ , donde  $e(k)$  es una secuencia discreto de ruido blanco.

**Objetivo** Estimar el parametro  $a$ .

3. Obtiene el estimado de mínimos cuadrados

$$\begin{aligned}\theta_{LS} &= (\Phi^T \Phi)^{-1} \Phi^T y \\ &= \left( \begin{bmatrix} -y_1 & -y_2 & \cdots & -y_{N-1} \end{bmatrix} \begin{bmatrix} -y_1 \\ -y_2 \\ \vdots \\ -y_{N-1} \end{bmatrix} \right)^{-1} \begin{bmatrix} -y_1 & -y_2 & \cdots & -y_{N-1} \end{bmatrix} \begin{bmatrix} y_2 \\ y_3 \\ \vdots \\ y_N \end{bmatrix} \\ &= - \frac{\sum_{k=1}^{N-1} y_k y_{k+1}}{\sum_{k=1}^{N-1} y_k^2}\end{aligned}$$

## Computación de la solución de mínimos cuadrados

Dado error de predicción en forma vectorial para sistema de orden  $n \in y - \Phi\theta$ . Forma las **ecuaciones normales**

$$\Phi\theta = y$$
$$\begin{bmatrix} \varphi_{n+1}^T \\ \varphi_{n+2}^T \\ \varphi_{n+3}^T \\ \varphi_{n+4}^T \\ \vdots \\ \varphi_N^T \end{bmatrix} \begin{bmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_m \end{bmatrix} = \begin{bmatrix} y_{n+1} \\ y_{n+2} \\ y_{n+3} \\ y_{n+4} \\ \vdots \\ y_N \end{bmatrix}$$

Resuelva las ecuaciones normales usando métodos numericamente robustos de algebra lineal, por ejemplo factorización L-U. En matlab se escribe

```
theta_LS = Phi \ y
```

# Ejemplo numerico

Mybinder



## Modelo autorregresivo (AR) - Ejercicio

Dado una secuencia discreta observada  $y(k)$ ,  $k = 1, 2, \dots, N$ , y el modelo autorregresivo de segunda orden

$$y(k+2) = a_1 y(k+1) + a_2 y(k) + e(k+2),$$

dónde  $e(k)$  es una secuencia discreto de ruido blanco.

**Actividad** Forma las ecuaciones normales

$$\Phi\theta = y$$

siguiendo los mismos pasos como en el ejemplo de primer orden.