Control computarizado - Identificación de sistemas

Kjartan Halvorsen

July 20, 2020

Identificación de sistemas

Un proceso complejo

From Wikipedia "Cyclonic separation"

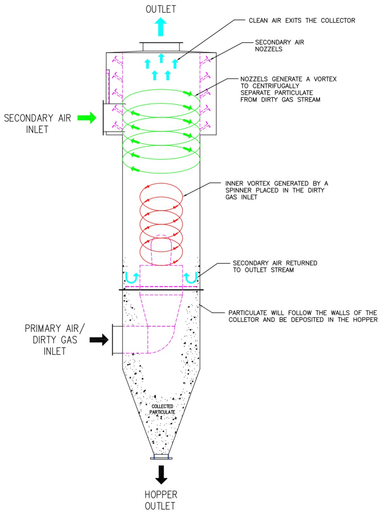

Identificación de sistemas

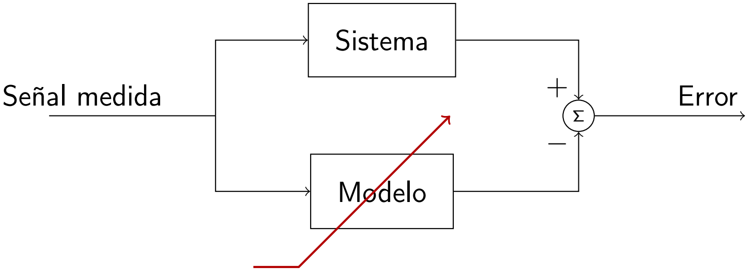

Ajustando un modelo - regresión lineal

Objetivo Dado observaciones

$$\mathcal{D} = \{(x_1, y_1), (x_2, y_2), \ldots, (x_N, y_N)\}$$

y modelo $\mathcal{M}: \; y = ax + b + e$, obtiene los parametros (a, b) que da el modelo que mejor se ajuste a los datos.
El término de ruido, o error, e, incluye errores de modelación y perturbaciones.

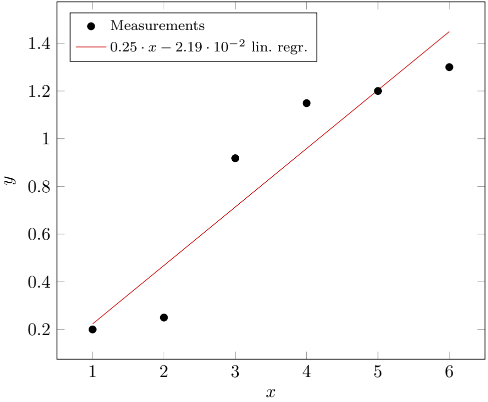

Ajustando un modelo - regresión lineal

Dado observaciones $\mathcal{D} = \{(x_1, y_1), (x_2, y_2), \ldots, (x_N, y_N)\}$ y modelo $\mathcal{M}: \; y = ax + b + e$.

La predicción es

$$\hat{y}_k = ax_k + b = \underbrace{\begin{bmatrix} x & 1 \end{bmatrix}}_{\varphi_k^T} \underbrace{\begin{bmatrix} a \\ b \end{bmatrix}}_{\theta}$$

y el error de predicción

$$\epsilon_k = y_k - \hat{y}_k = y_k - ax_k - b = y - \varphi_k^T \theta.$$

Buscamos parametros $\theta^T = \begin{bmatrix} a & b \end{bmatrix}$ que minimiza la función de pérdida

$$J(\theta) = \sum_{k=1}^{N} g(\epsilon_k).$$

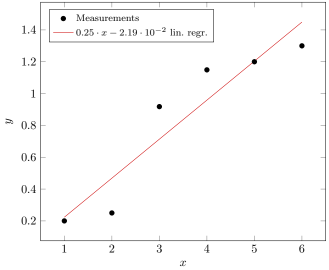

Ajustando un modelo - regresión lineal

Dado observaciones $\mathcal{D} = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ y modelo $\mathcal{M}: \; y = ax + b + e$.

La función de pérdida más común es mínimos cuadrados

$$
\begin{aligned}
\hat{\theta}_{LS} &= \arg\min J_{LS}(\theta) = \arg\min \sum_{k=1}^{N} \epsilon_k^2 \\
&= \arg\min \sum_{k=1}^{N} (y_k - \hat{y}_k)^2 = \arg\min \sum_{k=1}^{N} (y_k - \varphi_k \theta)^2 \\
&= \arg\min \sum_{k=1}^{N} (y_k - a x_k - b)^2
\end{aligned}
$$

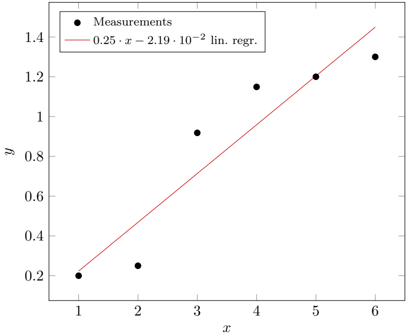

El problema con mínimos cuadrados

$$\text{minimiza} \sum_k g(\epsilon_k)$$

dónde $g(u) = u^2$

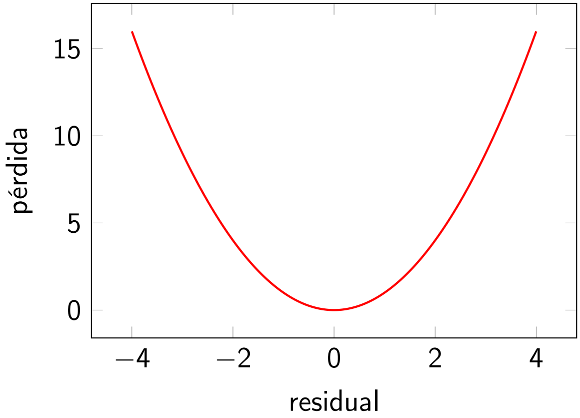

Más robusta: La función de pérdida de Huber

También conocido como regresión robusta

$$\text{minimiza } \sum_k g_{hub}(\epsilon_k)$$

dónde $g_{hub}(u) = \begin{cases} u^2 & |u| \leq M \\ M(2|u| - M) & |u| > M \end{cases}$

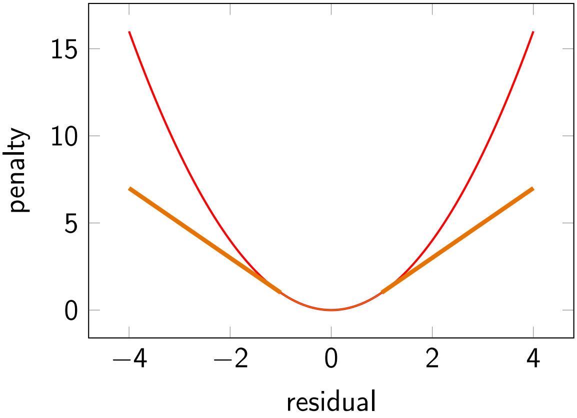

Ejemplo - Modelo autoregresivo (AR)

Modelo autoregresivo (AR)

Dado una secuencia discreta observada $y(k),\ k = 1, 2, \ldots, N$, y el modelo autoregresivo

$$y(k+1) = -ay(k) + e(k+1),$$

dónde $e(k)$ es una sequencia discreto de ruido blanco.

Objetivo Estimar el parametro a.

1. Forma el predictor de un paso adelante

$$\hat{y}_{k+1} = -ay_k = -y_k a = \varphi_{k+1}\theta,$$

y el error de predicción

$$\epsilon_k = y_k - \hat{y}_k = y_k - \varphi_k\theta$$

Modelo autoregresivo (AR)

Dado una secuencia discreta observada $y(k)$, $k = 1, 2, \ldots, N$, y el modelo autoregresivo $y(k+1) = -ay(k) + e(k+1)$, dónde $e(k)$ es una sequencia discreto de ruido blanco.

Objetivo Estimar el parametro a.

2. Reune todas las observaciónes y_k y predicciones $\hat{y}_k$ en forma vectoral

$$\epsilon = \begin{bmatrix} \epsilon_2 \\ \epsilon_2 \\ \vdots \\ \epsilon_N \end{bmatrix} = \begin{bmatrix} y_2 \\ y_3 \\ \vdots \\ y_N \end{bmatrix} - \begin{bmatrix} \hat{y}_2 \\ \hat{y}_3 \\ \vdots \\ \hat{y}_N \end{bmatrix} = \begin{bmatrix} y_2 \\ y_3 \\ \vdots \\ y_N \end{bmatrix} - \begin{bmatrix} -y_1 a \\ -y_2 a \\ \vdots \\ -y_{N-1}^T \theta \end{bmatrix} = \begin{bmatrix} y_2 \\ y_3 \\ \vdots \\ y_N \end{bmatrix} - \begin{bmatrix} \varphi_2^T \theta \\ \varphi_3^T \theta \\ \vdots \\ \varphi_N^T \theta \end{bmatrix}$$

$$= y - \underbrace{\begin{bmatrix} \varphi_1^T \\ \varphi_2^T \\ \vdots \\ \varphi_N^T \end{bmatrix}}_{\Phi} \theta = y - \Phi\theta$$

Modelo autoregresivo (AR)

Dado una secuencia discreta observada $y(k),\ k = 1, 2, \ldots, N$, y el modelo autoregresivo $y(k+1) = -ay(k) + e(k+1)$, dónde $e(k)$ es una sequencia discreto de ruido blanco.

Objetivo Estimar el parametro a.

3. Obtiene el estimado de mínimos cuadrados

$$
\begin{aligned}
\theta_{LS} &= (\Phi^T\Phi)^{-1}\Phi^T y \\
&= \left(\begin{bmatrix} -y_1 & -y_2 & \cdots & -y_{N-1} \end{bmatrix} \begin{bmatrix} -y_1 \\ -y_2 \\ \vdots \\ -y_{N-1} \end{bmatrix} \right)^{-1} \begin{bmatrix} -y_1 & -y_2 & \cdots & -y_{N-1} \end{bmatrix} \begin{bmatrix} y_2 \\ y_3 \\ \vdots \\ y_N \end{bmatrix} \\
&= -\frac{\sum_{k=1}^{N-1} y_k y_{k+1}}{\sum_{k=1}^{N-1} y_k^2}
\end{aligned}
$$

Computación de la solución de mínimos cuadrados

Dado error de predicción en forma vectorial para sistema de orden n $\epsilon = y - \Phi\theta$. Forma el sistema de ecuaciones

$$\Phi\theta = y$$

$$\begin{bmatrix} \varphi_{n+1}^T \\ \varphi_{n+2}^T \\ \varphi_{n+3}^T \\ \varphi_{n+4}^T \\ \vdots \\ \varphi_N^T \end{bmatrix} \begin{bmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_m \end{bmatrix} = \begin{bmatrix} y_{n+1} \\ y_{n+2} \\ yn+3 \\ y_{n+4} \\ \vdots \\ y_N \end{bmatrix}$$

Resuelva las ecuaciones usando métodos numericamente robustos de algebra lineal, por ejemplo factorización L-U. En matlab se escribe

```
theta_LS = Phi \ y
```

Ejemplo numerico

Mybinder

Model AR de orden n

Dado una secuencia discreta observada $y(k),\ k = 1, 2, \ldots, N$, y el modelo autoregresivo

$$
\begin{aligned}
A(z)Y(z) = z^n E(z) \quad &\Leftrightarrow \quad A(\mathrm{q})y(k) = \mathrm{q}^{n-1}\, e(k)\\
(\mathrm{q}^n + a_1\, \mathrm{q}^{n-1} + a_2\, \mathrm{q}^{n-2} + \cdots + a_n)y(k) &= \mathrm{q}^n\, e(k)\\
(\mathrm{q} + a_1 + a_2\, \mathrm{q} - 1 + \cdots + a_n\, \mathrm{q}^{-n+1})y(k) &= \mathrm{q}^{n-1}\, e(k)\\
y(k+1) + a_1 y(k) + a_2 y(k-1) + \cdots + a_n y(k-n+1) &= e(k+1)\\
y(k+1) = -a_1 y(k) - a_2 y(k-1) - \cdots - a_n y(k-n+1) &+ e(k+1)
\end{aligned}
$$

dónde $e(k)$ es una sequencia discreto de ruido blanco.

Objetivo Estimar los parametro $a_1, a_2, \ldots, n$.

Model AR de orden n

Dado una secuencia discreta observada $y(k)$, $k = 1, 2, \ldots, N$, y el modelo autoregresivo $y(k+1) = -a_1 y(k) - a_2 y(k-1) - \cdots - a_n y(k-n+1) + e(k+1)$.

1. Forma el predictor de un paso adelante

$$\hat{y}_{k+1} = -a_1 y_k - a_2 y_{k-1} - \ldots - a_n y_{k-n+1} a = \underbrace{\begin{bmatrix} -y_k & -y_{k-1} & \cdots & -y_{k-n+1} \end{bmatrix}}_{\varphi_{k+1}^T} \underbrace{\begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{bmatrix}}_{\theta}$$

y el error de predicción

$$\epsilon_k = y_k - \hat{y}_k = y_k - \varphi_k^T \theta$$

Model AR de orden n

Dado una secuencia discreta observada $y(k)$, $k = 1, 2, \ldots, N$, y el modelo autoregresivo $y(k+1) = -a_1 y(k) - a_2 y(k-1) - \cdots - a_n y(k-n+1) + e(k+1)$.

2. Reune todas las observaciónes y_k y predicciones $\hat{y}_k$ en forma vectoral

$$\epsilon = \begin{bmatrix} \epsilon_{n+1} \\ \epsilon_{n+2} \\ \vdots \\ \epsilon_N \end{bmatrix} = \begin{bmatrix} y_{n+1} \\ y_{n+2} \\ \vdots \\ y_N \end{bmatrix} - \begin{bmatrix} \hat{y}_{n+1} \\ \hat{y}_{n+2} \\ \vdots \\ \hat{y}_N \end{bmatrix} = \begin{bmatrix} y_{n+1} \\ y_{n+2} \\ \vdots \\ y_N \end{bmatrix} - \begin{bmatrix} \varphi_{n+1}^T \theta \\ \varphi_{n+2}^T \theta \\ \vdots \\ \varphi_N^T \theta \end{bmatrix}$$

$$= y - \underbrace{\begin{bmatrix} \varphi_{n+1}^T \\ \varphi_{n+2}^T \\ \vdots \\ \varphi_N^T \end{bmatrix}}_{\Phi} \theta = y - \Phi\theta$$

Model AR de orden n

Dado una secuencia discreta observada $y(k),\ k = 1, 2, \dots, N$, y el modelo autoregresivo $y(k+1) = -a_1 y(k) - a_2 y(k-1) - \cdots - a_n y(k-n+1) + e(k+1)$.

3. Obtiene el estimado de mínimos cuadrados, que es

$$\theta_{LS} = (\Phi^T \Phi)^{-1} \Phi^T y$$

formando y resolviendo el sistema de ecuaciones

$$\Phi\theta = y$$

$$\begin{bmatrix} \varphi_{n+1}^T \\ \varphi_{n+2}^T \\ \varphi_{n+3}^T \\ \varphi_{n+4}^T \\ \vdots \\ \varphi_N^T \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} y_{n+1} \\ y_{n+2} \\ y_{n+3} \\ y_{n+4} \\ \vdots \\ y_N \end{bmatrix}$$

Modelo autoregresivo (AR) - Ejercicio

Dado una secuencia discreta observada $y(k), \; k = 1, 2, \ldots, N$, y el modelo autoregresivo de segunda orden

$$y(k+2) + a_1 y(k+1) + a_2 y(k) = e(k+2),$$

dónde $e(k)$ es una sequencia discreto de ruido blanco.

Actividad Forma las ecuaciones

$$\Phi \theta = y$$

Model AutoRegresivo con variables eXógenas (ARX)

Dado señal discreta de entrada de un sistema $u(k)$, $k = 1, 2, \ldots, N$ y observaciones de la respuesta $y(k)$, $k = 1, 2, \ldots, N$, y el modelo ARX

$$A(\mathrm{q})y(k) = B(\mathrm{q})u(k) + e(k+n),$$

dónde $e(k)$ es una sequencia discreto de ruido blanco.

Actividad Llena los bloques